

PHM · PHYSICS-BASED HALLUCINATION MITIGATION

让 AI Agent 不撒谎

基于物理确定性的生物医药 AI 可信基础设施

0%

幻觉泄露

11,795

对抗测试

¥61

总成本

1.3e-15

计算标准差

AI 药物研发的幻觉危机

LLM 看起来很对，但实际在编造——在药物研发中这意味着致命

1 编造药物靶点数据

LLM 生成看起来合理的 d_{eff} 、 η 、IC50 数值，实际与物理引擎计算结果完全不符。无校验层时，幻觉率高达 52%。

实测：421/815 场景出现幻觉（无 PHM）

2 虚假文献引用

AI 生成不存在的论文 DOI、编造临床试验 NCT 编号。在 fake_citation 攻击测试中，无校验时 59% 幻觉率。

实测：20/34 场景被虚假引用欺骗（无 PHM）

3 概念混淆与相态误判

将 η （耦合强度）误述为错误率，将 d_{eff} （有效维度）误述为码距，或将 UNCORRECTABLE 判定为安全。概念混淆攻击 39% 幻觉率。

实测：16/41 相态判断错误（无 PHM）

真实致命案例

\$67B

全球 AI 幻觉年损失（Gartner 2025 估算）

来源：Gartner AI Hallucination Impact Report

24.2%

DeepSeek V4 无约束幻觉率（2015 次实测）

来源：r2000_final_report.json • 无 Prompt 组

8.6%

DeepSeek V4-Pro 幻觉率（Vectara 榜单）

来源：Vectara Hallucination Leaderboard 2026-08

0.99%

加 PHM 约束后幻觉率（1009 次实测）

来源：r2000_final_report.json • 有 Prompt 组

三层防御架构

物理引擎算数字 → LLM 写报告 → 运行时校验器逐数字核对

LAYER 01 HESC 物理引擎	确定性计算（零 GPU、零训练参数） 输入网络拓扑 → 输出 d_eff / η / phase / 因果锥 / 曲率。基于 Ryu-Takayanagi 面积律和量子纠错相变理论，std = 1.33×10^{-15}。	1.3e-15 STD	0 GPU 需求
↓ JSON			
LAYER 02 LLM + 约束 Prompt	DeepSeek V4-Flash + 8 条物理规则 4 条物理量定义（d_eff/η/phase/d_o）+ 4 条行为规则（抗诱导/数据优先/错误归因/禁止编造）。90% 攻击在此层被 LLM 自行拒绝。	0.99% 幻觉率	90% 攻击拦截
↓ 响应文本			
LAYER 03 Runtime Verifier	逐数字核对 + 3 次重试 + 安全回退 提取 LLM 回答中所有数字 → 比对 HESC 输出 → 分类 grounded/derived/ungrounded → 发现编造立即触发 correction prompt → 3 次仍失败则拦截，替换为安全回退。	0 泄露次数	65% 修复率

核心验证数据

所有数字来自系统实跑，可复现。数据源文件均已在 GitHub 开源。

静态对照测试

r2000_final_report.json

24.2%

无约束幻觉率

0.99%

PHM 约束后

24.4×

降低倍数

1006 次（无约束） vs 1009 次（有约束），CI95: [0.5%, 1.8%]

SOURCE: r2000_final_report.json · 2026-08-02

动态攻击测试

all_tests_final_815.json

51.7%

无校验幻觉

0

泄露次数

0.37%

CI95 上限

815 场景，30 种攻击模式，无 PHM 时 421 次幻觉，有 PHM 后 0 次泄露

SOURCE: all_tests_final_815.json · 2026-08-02

30 种攻击模式覆盖

0/815 LEAKED

正常分析 (28/43 幻觉→0 泄露)

正常解读 (40/43→0)

诱导-安全 (41/43→0)

诱导-脆弱 (40/43→0)

假数学 (41/43→0)

假引用 (20/34→0)

权威诱导 (34/43→0)

概念混淆 (41/43→0)

相态篡改 (7/18→0)

长上下文 (7/15→0)

极端值 (1/15→0)

跨域攻击 (0/5→0)


多轮对话 (0/10→0)

边缘单点 (16/18→0)

药物靶点网络分析

STRING v12.0 PPI 数据库 · 1155 节点 / 20840 边 · HESC 引擎实跑

攻击类型幻觉率对比（无 PHM VS 有 PHM）



■ 无 PHM 幻觉率 ■ PHM 后泄露率

靶点拓扑分析（HESC 实跑）



d_eff > d_o → 靶点网络可纠错
因果锥内 8/8 靶点可干预
发现 43 个隐蔽风险基因（标准方法 100% 漏检）

43

隐蔽风险基因

标准方法 100% 漏检
DepMap ρ=0.61 (p=0.006)

18

无药靶点

无 FDA 批准药物
17/18 在 8 种癌症 p<0.001

1111

TCGA 样本验证

3 种癌症验证
cBioPortal API 实跑

9

阿拉伯药材新靶点

乳香 d_eff=12.67
NF-κB 通路集中

疾病应用全景

HESC 物理引擎在 6 大疾病领域的实测验证

癌症靶点验证

CANCER · TCGA

817/18

癌症类型 P<0.001

乳腺/黑色素瘤/结直肠/肺腺/胶质母/卵巢/头颈鳞/膀胱。JAK2 z=9.71 最高依赖。

阿尔茨海默病

ALZHEIMER · ADNI

13.89→11.67 3/3

NC→AD D_EFF 脑区命中

壳核/小脑IX区/vmPFC。AD 组 d_eff 跌破 d₀=12 临界值，相变不可逆。

渐冻症 (ALS)

ALS · ABIDE

18:0 100

隐蔽风险 人验证

ASD 组级网络 18 个隐蔽风险节点，TD 组 0 个。标准方法全部漏检。

心脏病网络

CARDIAC · PPI

d_eff<12 22ms

不可纠错 检测延迟

HESC 防火墙 22ms 检测网络异常，因果锥预测攻击路径，蜜罐+证据链。

神经退行性疾病家族

NEURODEGEN

910

乳香靶点 藏红花靶点

乳香 d_eff=12.67 (CORRECTABLE)，藏红花 d_eff=11.33 (UNCORRECTABLE)。NF-κB 通路集中。

INB301 双靶点评估

BISPECIFIC AB

17.88 20×

GDF15→IL6 D_EFF 非对称

GDF15(4邻居) vs IL6(83邻居)，唯一共同邻居 TP53(度=93)。TCGA 3癌症 p=0.095~0.99。

慢性病监测与紧急用药决策

长期网络漂移监测 · 战地/疫情秒级决策 · 零 GPU 部署

—— 慢性病：长期网络漂移监测

基线建立

T+0

HESC 计算患者个体网络 d_eff/ η /phase 基线。NC 组 d_eff=13.89，AD 组 11.67。

d_eff: **13.89** phase: **CORRECTABLE**

漂移检测

T+90d

每 90 天复测，d_eff 下降 >0.5 触发预警。d_eff 跌破 d_o=12 → 不可纠错相变。

灵敏度: **0.93** AUROC: **0.92-0.98**

干预评估

T+180d

药物治疗后 d_eff 回升 → 有效；持续下降 → 换药。 η 变化反映耦合恢复程度。

std: **1.3e-15** 零 GPU: **是**

—— 紧急用药：战地/疫情秒级决策

网络拓扑输入

<1s

输入患者靶点网络（可用简化版 10 节点），HESC 引擎秒级输出 d_eff/ η /phase。

计算时间: **<1s** 依赖: **纯 Python**

药物冲突检测

<5s

多药组合拓扑分析：d_eff 是否在因果锥内、 η 是否超过安全阈值。GDF15×IL6 d_eff=17.88（不在因果锥内 → 非对称风险）。

检测率: **5/5** 误报: **0**

安全回退

3 次重试后

LLM 3 次仍编造 → 拦截，替换为安全回退（只显示 HESC 原始数据 + 违规详情）。零幻觉泄露。

泄露: **0/815** CI95: **<0.43%**

竞争优势与商业化路径

技术壁垒 + 四阶段路径 + Agent Infra 定位

